深蓝学院
shenlanxueyuan.com

视觉SLAM：从理论到实践
第四次课 相机模型 非线性优化

主讲人 高翔

清华大学 自动控制与工程 博士
慕尼黑工业大学计算机视觉组 博士后
Email: gao.xiang.thu@gmail.com

2018年 春

第四讲 相机模型 非线性优化

深蓝学院
shenlanxueyuan.com

1. 针孔相机模型与图像
2. 实践：OpenCV/RGBD图像拼接
3. 批量状态估计问题
4. 非线性最小二乘法
5. 实践：Ceres和g2o

往期内容回顾

1. SLAM的运动与观测模型

2. 观测模型具体形式？

1. 针孔相机模型

1. 针孔相机模型

- 现实生活中存在大量的照片
  - 照片记录了真实世界在成像平面上的投影
  - 这个过程丢弃了“距离”维度上的信息
  - 普通相机可以用针孔模型很好地近似

1. 针孔相机模型

深蓝学院
shenlanxueyuan.com

- 小孔成像模型

原始形式 $$\frac{Z}{f} = -\frac{X}{X'} = -\frac{Y}{Y'}.$$

翻转到前面 $$\frac{Z}{f} = \frac{X}{X'} = \frac{Y}{Y'}.$$

整理之：
$$X' = f\frac{X}{Z}$$
$$Y' = f\frac{Y}{Z}.$$

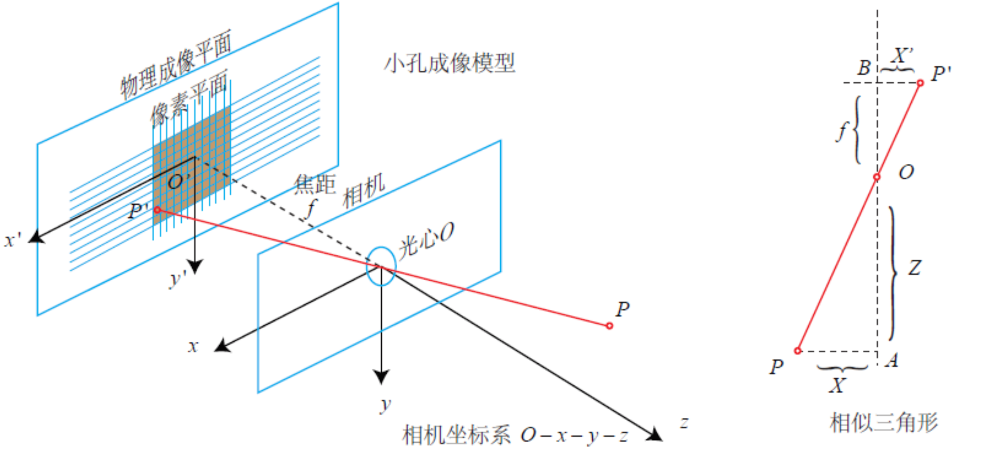

图 5-1　针孔相机模型

1. 针孔相机模型

- 小孔成像模型
- 成像平面到像素坐标

$$\begin{cases} u = \alpha X' + c_x \\ v = \beta Y' + c_y \end{cases}.$$

代入

$$\begin{aligned} X' &= f\frac{X}{Z} \\ Y' &= f\frac{Y}{Z} \end{aligned}.$$

得

$$\begin{cases} u = f_x \frac{X}{Z} + c_x \\ v = f_y \frac{Y}{Z} + c_y \end{cases}.$$

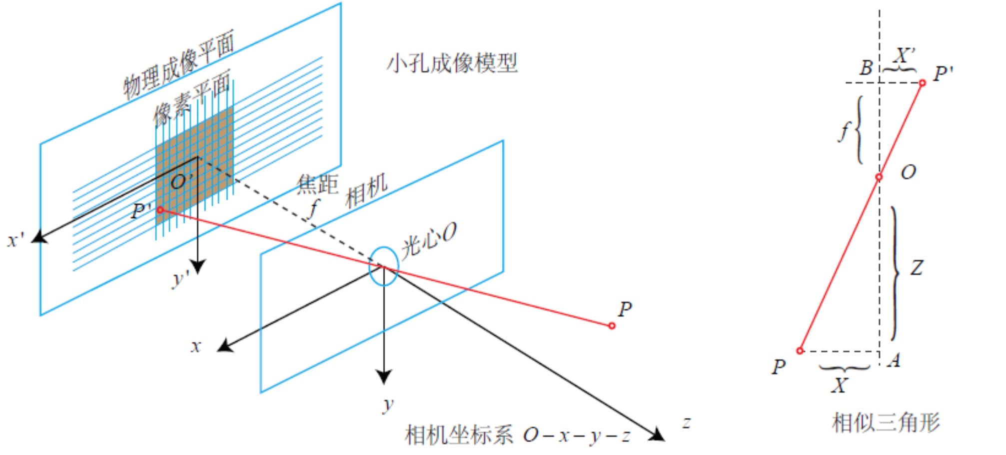

图 5-1 针孔相机模型

1. 针孔相机模型

深蓝学院
shenlanxueyuan.com

展开形式

$$\begin{cases} u = f_x \frac{X}{Z} + c_x \\ v = f_y \frac{Y}{Z} + c_y \end{cases}.$$

传统习惯

矩阵形式

$$\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \frac{1}{Z} \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \triangleq \frac{1}{Z} KP.$$

$$Z \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \triangleq KP.$$

左侧是齐次坐标　　　　右侧是非齐次坐标

中间矩阵称为内参数

内参通常在相机生产之后就已固定

1. 针孔相机模型

深蓝学院 shenlanxueyuan.com

$$Z\begin{pmatrix}u\\v\\1\end{pmatrix}=\begin{pmatrix}f_x & 0 & c_x\\0 & f_y & c_y\\0 & 0 & 1\end{pmatrix}\begin{pmatrix}X\\Y\\Z\end{pmatrix}\triangleq KP.$$

同一直线上的投影点仍是同一个

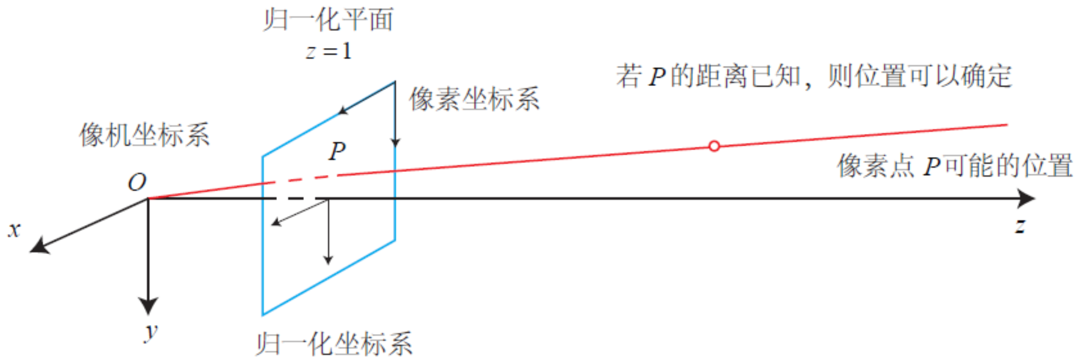

1. 针孔相机模型

深蓝学院
shenlanxueyuan.com

- 除内参外，相机坐标系与世界坐标系还相差一个变换：

$$Z P_{uv} = Z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K \left(R P_w + t \right) = K T P_w.$$

先把P从世界坐标变到
相机坐标系下

- 这里 R, t 或 T 称为外参
  - 注：右侧式子隐含了一次非齐次到齐次的变换（见书）
- 外参是SLAM估计的目标

1. 针孔相机模型

- 投影顺序：世界——相机——归一化平面——像素

激光数据的观测模型更加简单

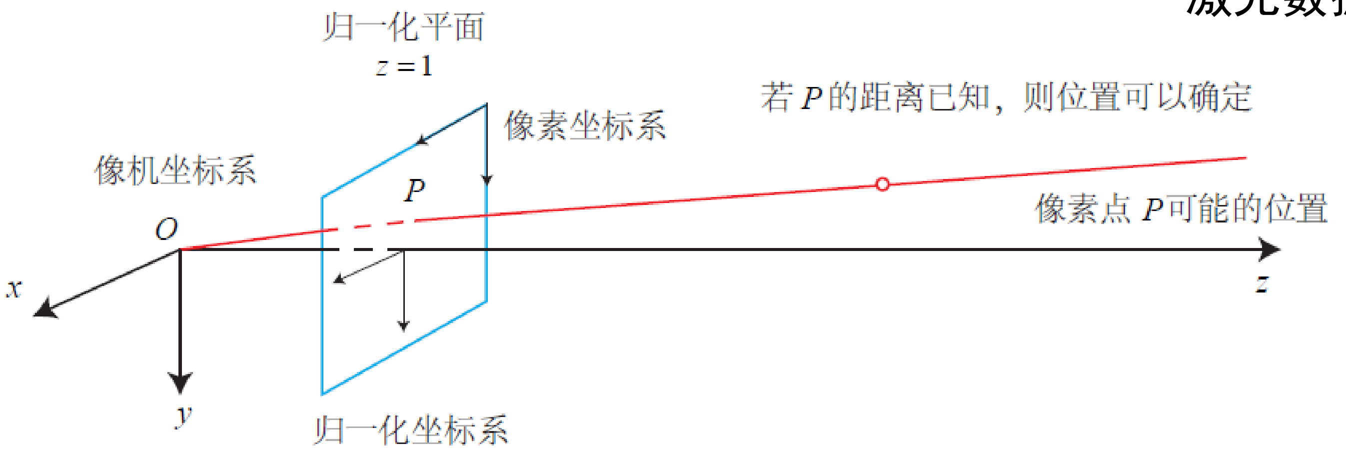

1. 针孔相机模型

- 畸变
  - 针孔前的镜头会引入畸变

广角镜头畸变

鱼眼镜头畸变

1. 针孔相机模型

- 主要的畸变类型：径向畸变和切向畸变

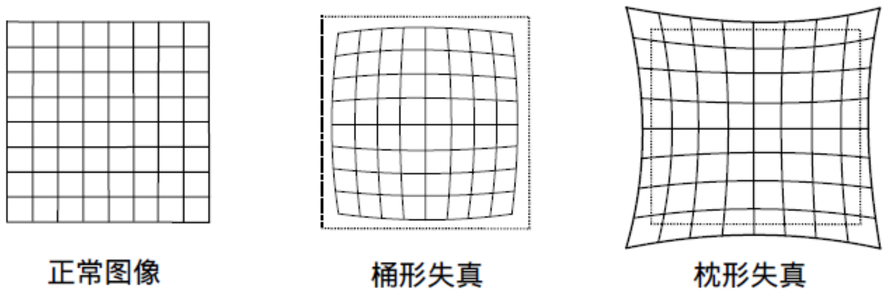

图 5-3　径向畸变的两种类型。

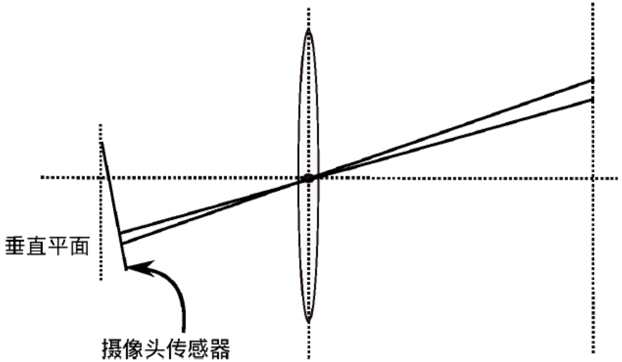

图 5-4　切向畸变来源示意图。

1. 针孔相机模型

- 数学模型
  - 畸变可以用归一化坐标的变换来描述

$$x_{distorted} = x\left(1 + k_1 r^2 + k_2 r^4 + k_3 r^6\right)$$
$$y_{distorted} = y\left(1 + k_1 r^2 + k_2 r^4 + k_3 r^6\right)$$

径向畸变：多项式描述

$$x_{distorted} = x + 2p_1 xy + p_2\left(r^2 + 2x^2\right)$$
$$y_{distorted} = y + p_1\left(r^2 + 2y^2\right) + 2p_2 xy$$

切向畸变：多项式描述

放在一起：
实际当中可灵活保留各项系数

$$\begin{cases} x_{distorted} = x\left(1 + k_1 r^2 + k_2 r^4 + k_3 r^6\right) + 2p_1 xy + p_2\left(r^2 + 2x^2\right) \\ y_{distorted} = y\left(1 + k_1 r^2 + k_2 r^4 + k_3 r^6\right) + p_1\left(r^2 + 2y^2\right) + 2p_2 xy \end{cases}$$

1. 针孔相机模型

- 小结

1. 首先，世界坐标系下有一个固定的点 P，世界坐标为 P_w；
2. 由于相机在运动，它的运动由 $\boldsymbol{R}, \boldsymbol{t}$ 或变换矩阵 $\boldsymbol{T} \in SE(3)$ 描述。P 的相机坐标为：$\tilde{\boldsymbol{P}}_c = \boldsymbol{R}\boldsymbol{P}_w + \boldsymbol{t}$。
3. 这时的 $\tilde{\boldsymbol{P}}_c$ 仍有 X, Y, Z 三个量，把它们投影到归一化平面 $Z = 1$ 上，得到 P 的归一化相机坐标：$\boldsymbol{P}_c = [X/Z, Y/Z, 1]^{T}$①。
4. 最后，P 的归一化坐标经过内参后，对应到它的像素坐标：$\boldsymbol{P}_{uv} = \boldsymbol{K}\boldsymbol{P}_c$。

1. 针孔相机模型

- 双目模型
  - 左右相机中心距离称为基线
  - 左右像素的几何关系：

$$\frac{z-f}{z} = \frac{b-u_L+u_R}{b}.$$

  - 整理得

$$z = \frac{fb}{d}, \quad d = u_L - u_R.$$

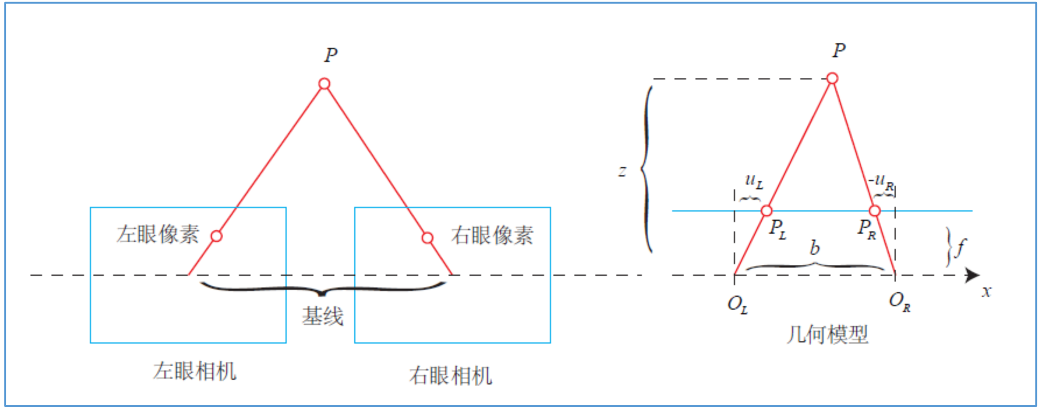

d称为视差（disparity），描述同一个点在左右目上成像的距离
d最小为1个像素，因此双目能测量的z有最大值：fb
虽然距离公式简单，但d不容易计算

1. 针孔相机模型

- RGB-D相机：物理手段测量深度
  - ToF或结构光两种主要原理
  - 通常能得到与RGB图对应的深度图

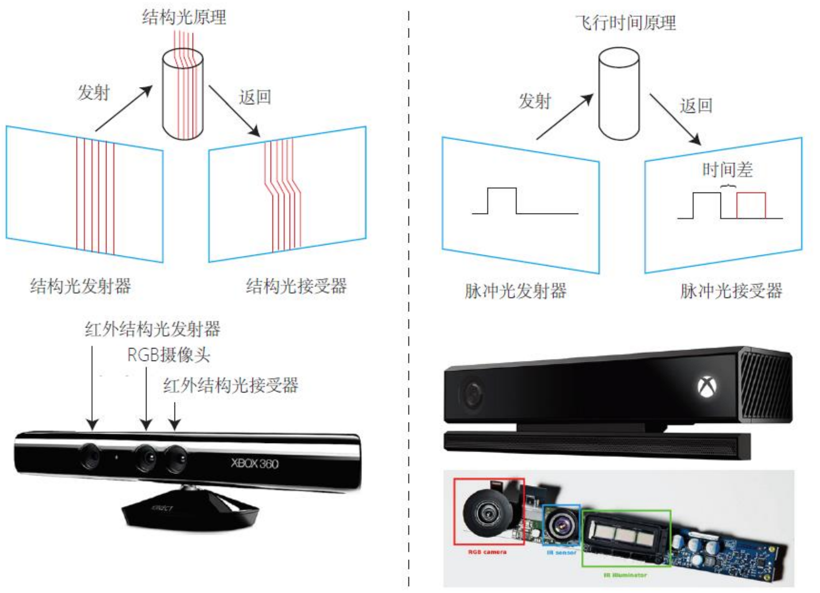

图 5-7　RGB-D 相机原理示意图

1. 针孔相机模型

- 相机成像后，生成了图像
- 图像在计算机中以矩阵形式存储（二维数组）
  - 需要对感光度量化成数值，例如0~255之间的整数（彩色图像还有通道）

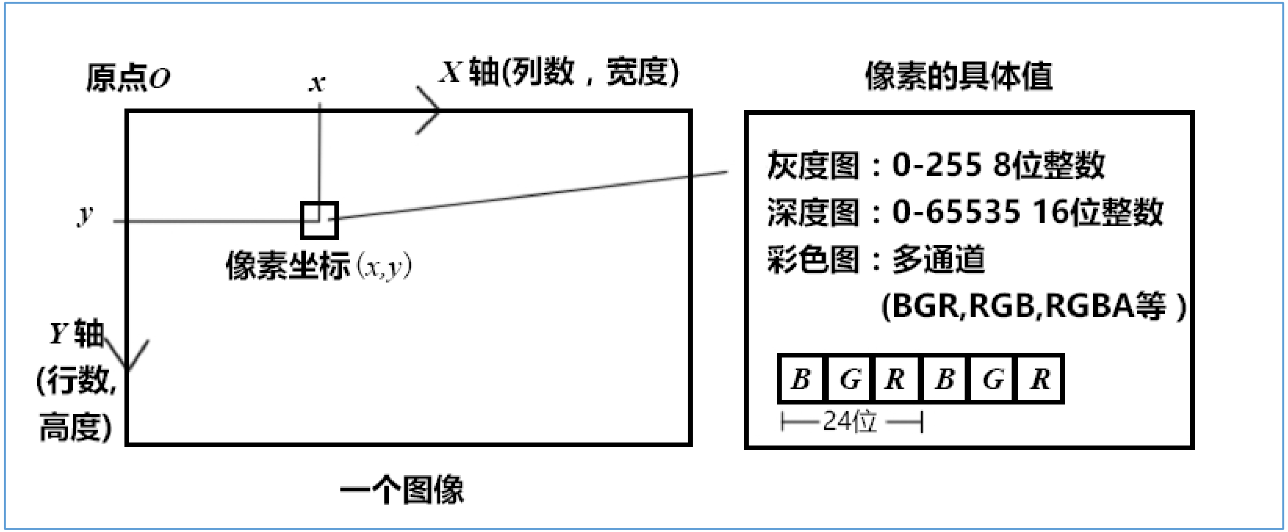

2. 实践：OpenCV/图像拼接

3. 批量状态估计问题

3. 批量状态估计问题

现在我们已探讨了观测模型

x为旋转+平移
h为相机观测模型

$$\left\{\begin{array}{l} \boldsymbol{x}_k = f\left(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k, \boldsymbol{w}_k\right) \\ \boldsymbol{z}_{k,j} = h\left(\boldsymbol{y}_j, \boldsymbol{x}_k, \boldsymbol{v}_{k,j}\right) \end{array}\right. .$$

问题：在给定模型和具体观测数据时，如何估计状态变量？

3. 批量状态估计问题

- 批量式（batch）
  - 一次给定所有的数据，估计所有的变量
  - 状态变量：

$$\boldsymbol{x} = \{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N, \boldsymbol{y}_1, \ldots, \boldsymbol{y}_M\}.$$

  - 求解： $P(\boldsymbol{x}|\boldsymbol{z}, \boldsymbol{u}).$

$$\begin{cases} \boldsymbol{x}_k = f\left(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k, \boldsymbol{w}_k\right) \\ \boldsymbol{z}_{k,j} = h\left(\boldsymbol{y}_j, \boldsymbol{x}_k, \boldsymbol{v}_{k,j}\right) \end{cases}.$$

  - 先不考虑运动方程，仅看观测方程（类似于SfM）
  - 贝叶斯法则：

$$P\left(\boldsymbol{x}|\boldsymbol{z}\right) = \frac{P\left(\boldsymbol{z}|\boldsymbol{x}\right)P\left(\boldsymbol{x}\right)}{P\left(\boldsymbol{z}\right)} \propto P\left(\boldsymbol{z}|\boldsymbol{x}\right)P\left(\boldsymbol{x}\right).$$

3. 批量状态估计问题

$$P(\boldsymbol{x}|\boldsymbol{z}) = \frac{P(\boldsymbol{z}|\boldsymbol{x})P(\boldsymbol{x})}{P(\boldsymbol{z})} \propto P(\boldsymbol{z}|\boldsymbol{x})P(\boldsymbol{x}).$$

- P(x|z) 条件分布很难求解，但可以求：
  a) 最大后验估计（Maximize a Posterior， MAP）

$$\boldsymbol{x}^*{}_{MAP} = \arg\max P(\boldsymbol{x}|\boldsymbol{z}) = \arg\max P(\boldsymbol{z}|\boldsymbol{x})P(\boldsymbol{x}).$$

  b) 最大似然估计（Maximize Likelihood Estimation, MLE）

$$\boldsymbol{x}^*{}_{MLE} = \arg\max P(\boldsymbol{z}|\boldsymbol{x}).$$

“在哪种状态下， 最容易产生当前的观测”

3. 批量状态估计问题

- 从最大似然到最小二乘
  - 例子：某次观测 $z_{k,j} = h\left(\boldsymbol{y}_j, \boldsymbol{x}_k\right) + \boldsymbol{v}_{k,j},$
  - 由于噪声是高斯的： $\boldsymbol{v}_k \sim N\left(0, \boldsymbol{Q}_{k,j}\right)$
  - 于是

$$P(\boldsymbol{z}_{j,k}|\boldsymbol{x}_k, \boldsymbol{y}_j) = N\left(h(\boldsymbol{y}_j, \boldsymbol{x}_k), \boldsymbol{Q}_{k,j}\right).$$

  - 现在要求x,y的最大似然估计，怎么求？

3. 批量状态估计问题

深蓝学院 shenlanxueyuan.com

- 一般的高斯分布：

$$P(\boldsymbol{x}) = \frac{1}{\sqrt{(2\pi)^N \det(\boldsymbol{\Sigma})}} \exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right).$$

- 负对数形式

$$-\ln(P(\boldsymbol{x})) = \frac{1}{2}\ln\left((2\pi)^N \det(\boldsymbol{\Sigma})\right) + \boxed{\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}).}$$

马氏距离

最小化x时，只和它有关

- 原问题的最大化，相当于负对数最小化
- 因此，关于原问题的最大似然：
- 相当于最小化：

$$P(\boldsymbol{z}_{j,k}|\boldsymbol{x}_k, \boldsymbol{y}_j) = N\left(h(\boldsymbol{y}_j, \boldsymbol{x}_k), \boldsymbol{Q}_{k,j}\right).$$

- 所有量加在一起：

$$\boldsymbol{x}^* = \arg\min\left(\left(\boldsymbol{z}_{k,j} - h(\boldsymbol{x}_k, \boldsymbol{y}_j)\right)^T \boldsymbol{Q}_{k,j}^{-1}\left(\boldsymbol{z}_{k,j} - h(\boldsymbol{x}_k, \boldsymbol{y}_j)\right)\right).$$

这货就是所谓的最小二乘

3. 批量状态估计问题

深蓝学院 shenlanxueyuan.com

- 我们把状态最大似然估计变成了最小二乘问题
- 对于原问题：

$$\left\{\begin{aligned} \boldsymbol{x}_k &= f\left(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k, \boldsymbol{w}_k\right) \\ \boldsymbol{z}_{k,j} &= h\left(\boldsymbol{y}_j, \boldsymbol{x}_k, \boldsymbol{v}_{k,j}\right) \end{aligned}\right. .$$

定义误差：

$$\begin{aligned} \boldsymbol{e}_{v,k} &= \boldsymbol{x}_k - f\left(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k\right) \\ \boldsymbol{e}_{y,j,k} &= \boldsymbol{z}_{k,j} - h\left(\boldsymbol{x}_k, \boldsymbol{y}_j\right), \end{aligned}$$

- **最小化误差的二范数：min** $J(\boldsymbol{x}) = \sum_k \boldsymbol{e}_{v,k}^T \boldsymbol{R}_k^{-1} \boldsymbol{e}_{v,k} + \sum_k \sum_j \boldsymbol{e}_{y,k,j}^T \boldsymbol{Q}_{k,j}^{-1} \boldsymbol{e}_{y,k,j}.$

3. 批量状态估计问题

- 直观解释
  - 由于噪声的存在，当我们把估计的轨迹与地图代入SLAM的运动、观测方程中时，它们并不会完美的成立。
  - 此时就调整状态的估计，使得误差最小化
- 该问题有何结构？
  - 由许多个误差的平方和（或Sigma范数和）组成。
  - 虽然总体维度高，但每个项很简单，只关联2个变量。
  - 如果用李代数表达位姿，那么是无约束优化问题。
- 如何求解？
  - 下面先来介绍通用的非线性最小二乘问题。

4. 非线性最小二乘

4. 非线性最小二乘

- 先考虑简单的问题：$\min_x \frac{1}{2}\|f(x)\|_2^2.$ 这里 $x \in \mathbb{R}^n$ ，f 为任意函数
- 当 f 很简单时：
  - 解： $\frac{\mathrm{d}f}{\mathrm{d}x} = 0.$ 将得到极值点或鞍点，比较这些解即可
- 当 f 复杂时：
  - df/dx难求，或df/dx=0很难解
  - 使用迭代方式求解

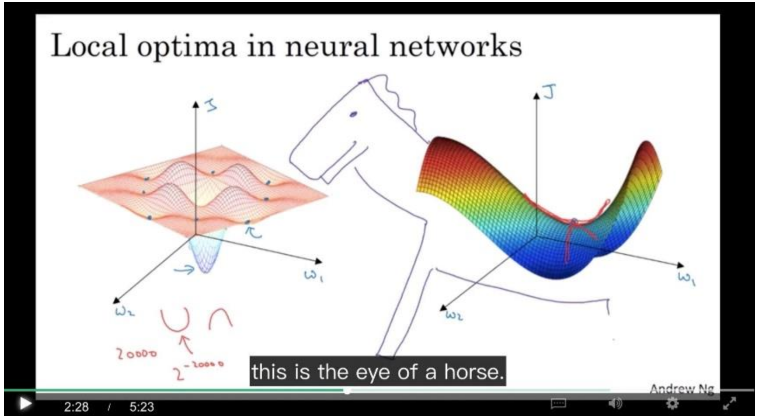

4. 非线性最小二乘

- 迭代方式：

问题：如何确定这个增量？

1. 给定某个初始值 $\boldsymbol{x}_0$。
2. 对于第 k 次迭代，寻找一个增量 $\Delta\boldsymbol{x}_k$，使得 $\|f(\boldsymbol{x}_k+\Delta\boldsymbol{x}_k)\|_2^2$ 达到极小值。
3. 若 $\Delta\boldsymbol{x}_k$ 足够小，则停止。
4. 否则，令 $\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\Delta\boldsymbol{x}_k$，返回 2.

4. 非线性最小二乘

- 确定增量的方法（即梯度下降策略）：一阶的或二阶的
- 泰勒展开：
$$\|f(\boldsymbol{x}+\Delta \boldsymbol{x})\|_2^2 \approx \|f(\boldsymbol{x})\|_2^2 + \boldsymbol{J}(\boldsymbol{x})\Delta \boldsymbol{x} + \frac{1}{2}\Delta \boldsymbol{x}^T \boldsymbol{H} \Delta \boldsymbol{x}.$$
- 若只保留一阶梯度：

$$\min_{\Delta x} \|f(x)\|_2^2 + J\Delta x$$

增量的方向： $\Delta \boldsymbol{x}^* = -\boldsymbol{J}^T(\boldsymbol{x}).$ （通常还需要计算步长）

- 称为最速下降法（Steepest Method）

4. 非线性最小二乘

- 若保留二阶梯度：

$$\|f(\boldsymbol{x}+\Delta\boldsymbol{x})\|_2^2 \approx \|f(\boldsymbol{x})\|_2^2 + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x} + \frac{1}{2}\Delta\boldsymbol{x}^T\boldsymbol{H}\Delta\boldsymbol{x}.$$

$$\Delta\boldsymbol{x}^* = \arg\min \|f(\boldsymbol{x})\|_2^2 + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x} + \frac{1}{2}\Delta\boldsymbol{x}^T\boldsymbol{H}\Delta\boldsymbol{x}.$$

- 则得到（令上式关于 Δx 的导数为零）： $\boldsymbol{H}\Delta\boldsymbol{x} = -\boldsymbol{J}^T.$

- 该方法又称为牛顿法

4. 非线性最小二乘

- 最速下降法和牛顿法虽然直观，但实用当中存在一些缺点
  - 最速下降法会碰到zigzag问题（过于贪婪）
  - 牛顿法迭代次数少，但需要计算复杂的Hessian矩阵
- 能否回避Hessian的计算？
  - Gauss-Newton
  - Levenberg-Marquadt

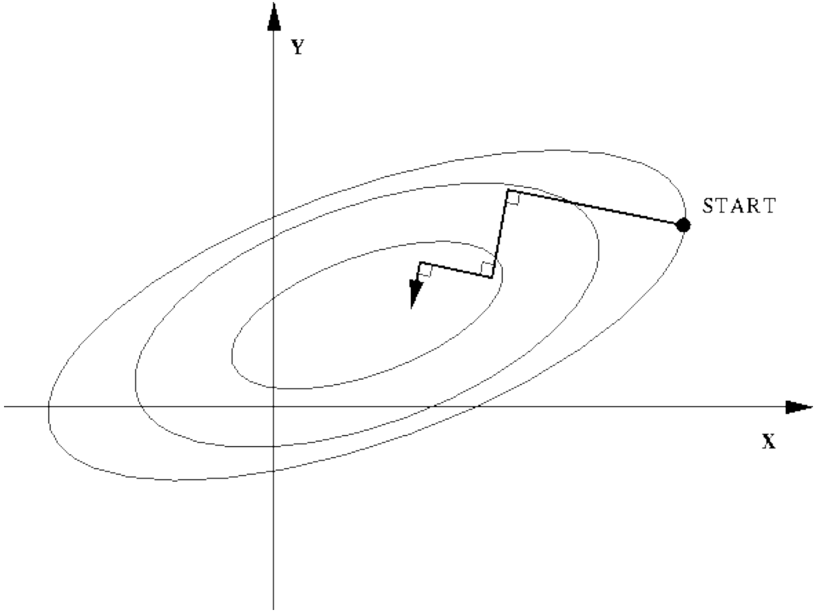

4. 非线性最小二乘

- Gauss-Newton
  - 一阶近似 f(x)： $f\left(\boldsymbol{x}+\Delta \boldsymbol{x}\right) \approx f\left(\boldsymbol{x}\right)+\boldsymbol{J}\left(\boldsymbol{x}\right)\Delta \boldsymbol{x}.$
  - 平方误差变为：

$$\begin{aligned}\frac{1}{2}\left\|f\left(\boldsymbol{x}\right)+\boldsymbol{J}\left(\boldsymbol{x}\right)\Delta \boldsymbol{x}\right\|^{2} &= \frac{1}{2}\left(f\left(\boldsymbol{x}\right)+\boldsymbol{J}\left(\boldsymbol{x}\right)\Delta \boldsymbol{x}\right)^{T}\left(f\left(\boldsymbol{x}\right)+\boldsymbol{J}\left(\boldsymbol{x}\right)\Delta \boldsymbol{x}\right)\\ &= \frac{1}{2}\left(\|f(\boldsymbol{x})\|_2^2+2f\left(\boldsymbol{x}\right)^{T}\boldsymbol{J}(\boldsymbol{x})\Delta \boldsymbol{x}+\Delta \boldsymbol{x}^{T}\boldsymbol{J}(\boldsymbol{x})^{T}\boldsymbol{J}(\boldsymbol{x})\Delta \boldsymbol{x}\right).\end{aligned}$$

  - 令关于 Δx 导数为零：

$$2\boldsymbol{J}\left(\boldsymbol{x}\right)^{T}f\left(\boldsymbol{x}\right)+2\boldsymbol{J}\left(\boldsymbol{x}\right)^{T}\boldsymbol{J}\left(\boldsymbol{x}\right)\Delta \boldsymbol{x}=\mathbf{0}.$$

$$\boldsymbol{J}(\boldsymbol{x})^{T}\boldsymbol{J}\left(\boldsymbol{x}\right)\Delta \boldsymbol{x}=-\boldsymbol{J}(\boldsymbol{x})^{T}f\left(\boldsymbol{x}\right).$$

$$\Rightarrow \quad \boldsymbol{H}\Delta \boldsymbol{x}=\boldsymbol{g}.$$

4. 非线性最小二乘

$$J(x)^T J(x) \Delta x = -J(x)^T f(x).$$ $\Rightarrow$ $$H \Delta x = g.$$

- G-N用J的表达式近似了H
- 步骤：

1. 给定初始值 $\boldsymbol{x}_0$。
2. 对于第 k 次迭代，求出当前的雅可比矩阵 $\boldsymbol{J}(\boldsymbol{x}_k)$ 和误差 $f(\boldsymbol{x}_k)$。
3. 求解增量方程：$\boldsymbol{H} \Delta \boldsymbol{x}_k = \boldsymbol{g}$.
4. 若 $\Delta \boldsymbol{x}_k$ 足够小，则停止。否则，令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \Delta \boldsymbol{x}_k$，返回 2.

4. 非线性最小二乘

- Gauss-Newton简单实用，但$\Delta x_k = H^{-1}g$ 无法保证H可逆
- Levenberg-Marquadt 方法一定程度上改善了它
  - G-N属于线搜索方法：先找到方向，再确定长度
  - L-M属于信赖区域方法（Trust Region），认为近似只在区域内可靠
    - 考虑近似程度的描述

$$\rho = \frac{f(\boldsymbol{x} + \Delta \boldsymbol{x}) - f(\boldsymbol{x})}{\boldsymbol{J}(\boldsymbol{x}) \Delta \boldsymbol{x}}.$$

实际下降/近似下降

    - 若太小，则减小近似范围
    - 若太大，则增加近似范围

4. 非线性最小二乘

- 改进版的G-N：

1. 给定初始值 $\boldsymbol{x}_0$，以及初始优化半径 μ。
2. 对于第 k 次迭代，求解：

$$\min_{\Delta \boldsymbol{x}_k} \frac{1}{2}\left\|f\left(\boldsymbol{x}_k\right)+\boldsymbol{J}\left(\boldsymbol{x}_k\right) \Delta \boldsymbol{x}_k\right\|^2, \quad s.t. \left\|\boldsymbol{D} \Delta \boldsymbol{x}_k\right\|^2 \leq \mu, \tag{6.24}$$

   这里 μ 是信赖区域的半径，$\boldsymbol{D}$ 将在后文说明。
3. 计算 ρ。
4. 若 $\rho > \frac{3}{4}$，则 $\mu = 2\mu$；
5. 若 $\rho < \frac{1}{4}$，则 $\mu = 0.5\mu$；
6. 如果 ρ 大于某阈值，认为近似可行。令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \Delta \boldsymbol{x}_k$。
7. 判断算法是否收敛。如不收敛则返回 2，否则结束。

4. 非线性最小二乘

深蓝学院 shenlanxueyuan.com

- Trust Region内的优化，利用Lagrange乘子转化为无约束：

$$\min_{\Delta x_k} \frac{1}{2} \| f(x_k) + J(x_k) \Delta x_k \|^2 + \frac{\lambda}{2} \| D \Delta x \|^2 .$$

- 仍参照G-N展开，增量方程为： $(H + \lambda D^T D) \Delta x = g.$

- 在Levenberg方法中，取D=I，则：$(H + \lambda I) \Delta x = g.$

4. 非线性最小二乘

$$(H + \lambda I)\,\Delta x = g.$$

- LM相比于GN，能够保证增量方程的正定性
  - 即，认为近似只在一定范围内成立，如果近似不好则缩小范围
- 从增量方程上来看，可以看成一阶和二阶的混合
  - 参数 λ 控制着两边的权重

4. 非线性最小二乘

- 小结
  - 非线性优化是个很大的主题，研究者们为之奋斗多年
  - 主要方法：最速下降、牛顿、G-N、L-M、DogLeg等
  - 与线性规划不同，非线性需要针对具体问题具体分析
  - 问题非凸时，对初值敏感，会陷入局部最优
    - 目前没有非凸问题的通用最优值的寻找办法
    - 问题凸时，二阶方法通常一两步就能收敛

5. 实践：Ceres and g2o

5. 实践

- Google Ceres Solver
  - 通用最小二乘问题求解库
  - 最一般的形式（带边界的核函数最小二乘）

$$\begin{aligned} \min_{x} \quad & \frac{1}{2} \sum_{i} \rho_i \left(\left\| f_i \left(x_{i_1}, \ldots x_{i_n} \right) \right\|^2 \right) \\ s.t. \quad & l_j \le x_j \le u_j. \end{aligned}$$

  - f 在Ceres中称为代价函数（Cost Function），x称为参数块（Parameter Block）

5. 实践

- 实验：曲线拟合
- 设曲线方程： $y = \exp(ax^2 + bx + c) + w,$
- 我们得到一些带噪声的样本数据：x, y
- 希望拟合（回归）曲线参数：a, b, c

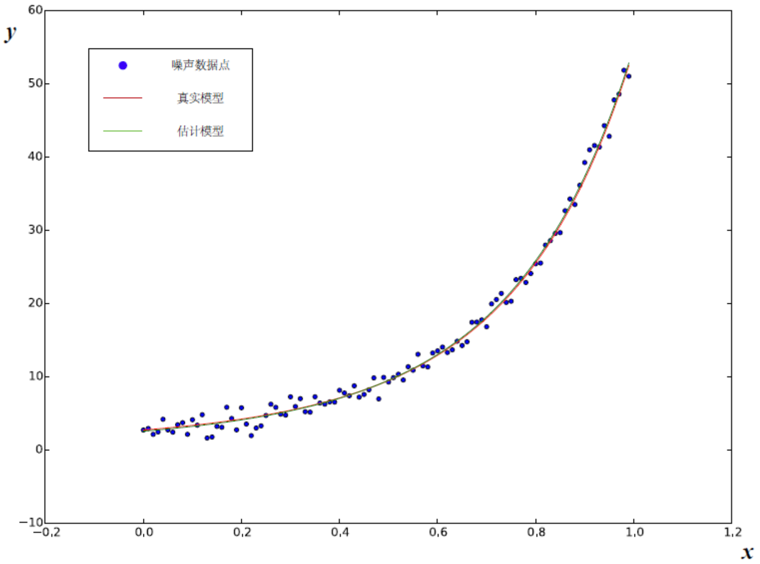

5. 实践

- G2O中以图模型表达上述最小二乘问题

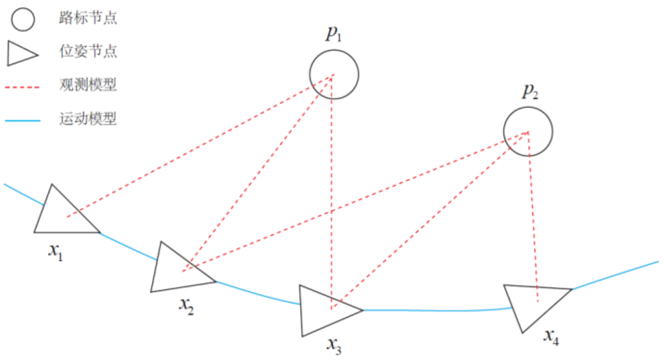

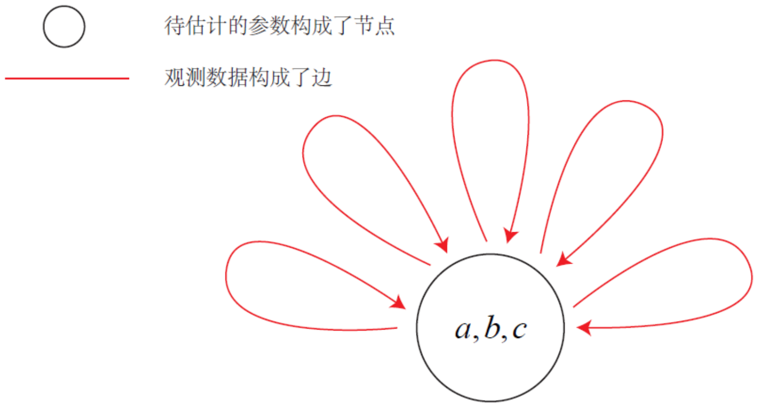

曲线拟合实验